

# WEBSERV

---

# Sommaire

---

- 1. Concepts Fondamentaux HTTP**
- 2. Architecture du Serveur**
- 3. I/O Multiplexing avec epoll/select/poll**
- 4. Parsing et Configuration**
- 5. Gestion des Requêtes HTTP**
- 6. CGI (Common Gateway Interface)**
- 7. Questions Fréquentes de Défense**
- 8. Checklist de Vérification**

# 1. Concepts Fondamentaux HTTP

## Qu'est-ce que HTTP ?

**HTTP (HyperText Transfer Protocol)** est un protocole de communication client-serveur qui fonctionne sur TCP/IP.

### Caractéristiques principales :

- **Sans état (stateless)** : chaque requête est indépendante
- **Basé sur du texte** : les messages sont lisibles
- **Port par défaut** : 80 (HTTP) ou 443 (HTTPS)
- **Méthodes principales** : GET, POST, DELETE

## Structure d'une Requête HTTP

```
GET /index.html HTTP/1.1 Host: www.example.com User-Agent: Mozilla/5.0 Accept: text/html  
Connection: keep-alive [Corps de la requête si POST]
```

### Composants :

1. **Request Line** : Méthode + URI + Version HTTP
2. **Headers** : Métadonnées (Host, User-Agent, etc.)
3. **Body** : Données (optionnel, pour POST)

## Structure d'une Réponse HTTP

```
HTTP/1.1 200 OK Content-Type: text/html Content-Length: 1234 Connection: keep-alive  
<html>...</html>
```

### Composants :

1. **Status Line** : Version + Code statut + Message
2. **Headers** : Content-Type, Content-Length, etc.
3. **Body** : Contenu de la réponse

# Codes de Statut HTTP

## Codes Importants à Connaître

Code	Signification	Utilisation
<b>200</b>	OK	Requête réussie
<b>201</b>	Created	Ressource créée (POST)
<b>204</b>	No Content	Succès sans contenu (DELETE)
<b>301</b>	Moved Permanently	Redirection permanente
<b>400</b>	Bad Request	Requête malformée
<b>403</b>	Forbidden	Accès interdit
<b>404</b>	Not Found	Ressource introuvable
<b>405</b>	Method Not Allowed	Méthode non autorisée
<b>413</b>	Payload Too Large	Body trop grand
<b>500</b>	Internal Server Error	Erreur serveur
<b>505</b>	HTTP Version Not Supported	Version HTTP non supportée

### ⚠️ Important pour la Défense

Vous devez pouvoir expliquer :

- Pourquoi vous retournez tel ou tel code
- La différence entre 301 et 302 (redirection permanente vs temporaire)
- Quand utiliser 204 vs 200
- Comment gérer les erreurs 4xx vs 5xx

## 2. Architecture du Serveur

### Vue d'Ensemble

Le serveur webserv suit une architecture non-bloquante avec I/O multiplexing.

#### Composants Principaux :

1. **Server** : Gère les sockets d'écoute
2. **Client** : Représente une connexion client
3. **Request Parser** : Parse les requêtes HTTP
4. **Response Builder** : Construit les réponses
5. **Config Parser** : Lit le fichier de configuration
6. **CGI Handler** : Exécute les scripts CGI

### Flux de Traitement

1. Configuration du serveur ↓ 2. Crédation des sockets d'écoute ↓ 3. Boucle epoll/select/poll ↓ 4. Acceptation de nouvelles connexions ↓ 5. Lecture des requêtes (non-bloquant) ↓ 6. Parsing de la requête ↓ 7. Traitement (fichier statique ou CGI) ↓ 8. Construction de la réponse ↓ 9. Envoi de la réponse (non-bloquant) ↓ 10. Fermeture ou keep-alive

### Sockets et Binding

```
// Crédation d'un socket int socket_fd = socket(AF_INET, SOCK_STREAM, 0); // Configuration  
d'adresse sockaddr_in addr; addr.sin_family = AF_INET; addr.sin_port = htons(8080);  
addr.sin_addr.s_addr = INADDR_ANY; // Binding bind(socket_fd, (struct sockaddr*)&addr,  
sizeof(addr)); // Listen listen(socket_fd, SOMAXCONN); // Accept (dans la boucle) int client_fd =  
accept(socket_fd, NULL, NULL);
```

### 3. ↘ I/O Multiplexing (epoll/select/poll)

#### Pourquoi le Multiplexing ?

Permet de gérer **plusieurs connexions simultanées** avec un seul thread, sans bloquer.

##### Problème sans Multiplexing :

- Un thread par client = inefficace et coûteux
- Opérations bloquantes = serveur gelé

##### Solution avec Multiplexing :

- Un seul thread surveille tous les sockets
- Traite uniquement les sockets prêts
- Non-bloquant et scalable

#### Comparaison : select vs poll vs epoll

Fonctionnalité	select	poll	epoll
<b>Limite FD</b>	1024 (FD_SETSIZE)	Illimité	Illimité
<b>Performance</b>	O(n)	O(n)	O(1)
<b>Portabilité</b>	Maximum	POSIX	Linux only
<b>Edge-triggered</b>	Non	Non	Oui

#### Exemple avec epoll

```
// Création de l'instance epoll
int epoll_fd = epoll_create1(0); // Ajout d'un socket à surveiller
struct epoll_event event;
event.events = EPOLLIN; // Lecture disponible
event.data.fd = socket_fd;
epoll_ctl(epoll_fd, EPOLL_CTL_ADD, socket_fd, &event); // Boucle principale
struct epoll_event events[MAX_EVENTS];
while (true) {
    int n = epoll_wait(epoll_fd, events, MAX_EVENTS, -1);
    for (int i = 0; i < n; i++) {
        if (events[i].events & EPOLLIN) { // Données à lire
            handleRead(events[i].data.fd);
        } if (events[i].events & EPOLLOUT) { // Prêt à écrire
            handleWrite(events[i].data.fd);
        }
    }
}
```



## Exemple avec select

```
fd_set read_fds, write_fds; int max_fd = 0; while (true) { FD_ZERO(&read_fds);  
FD_ZERO(&write_fds); // Ajouter tous les sockets FD_SET(server_fd, &read_fds); max_fd =  
server_fd; for (auto& client : clients) { FD_SET(client.fd, &read_fds); if (client.has_data_to_send)  
FD_SET(client.fd, &write_fds); if (client.fd > max_fd) max_fd = client.fd; } // Attendre des  
événements select(max_fd + 1, &read_fds, &write_fds, NULL, NULL); // Traiter les événements  
if (FD_ISSET(server_fd, &read_fds)) { // Nouvelle connexion acceptClient(); } for (auto& client :  
clients) { if (FD_ISSET(client.fd, &read_fds)) { readFromClient(client); } if (FD_ISSET(client.fd,  
&write_fds)) { writeToClient(client); } }
```

### Pièges Communs

- **Oublier fcntl()** : Les sockets doivent être en mode non-bloquant
- **select() modifie les fd\_set** : Il faut les reconstruire à chaque itération
- **EAGAIN/EWOULDBLOCK** : Normal en non-bloquant, ne pas considérer comme  
erreur
- **Broken pipe** : Le client se déconnecte, gérer proprement

## 4. Parsing et Configuration

### Fichier de Configuration

Similaire à nginx, avec des directives en blocs.

```
server { listen 8080; server_name localhost; client_max_body_size 10M; location / { root /var/www; index index.html; autoindex on; allow_methods GET POST; } location /upload { allow_methods POST DELETE; upload_path /var/www/uploads; } location /cgi-bin { cgi_pass .py /usr/bin/python3; cgi_pass .php /usr/bin/php-cgi; } error_page 404 /404.html; }
```

### Directives Importantes

Directive	Description
<b>listen</b>	Port d'écoute du serveur
<b>server_name</b>	Nom du serveur (virtual host)
<b>root</b>	Répertoire racine des fichiers
<b>index</b>	Fichier par défaut
<b>allow_methods</b>	Méthodes HTTP autorisées
<b>client_max_body_size</b>	Taille max du body
<b>autoindex</b>	Listing de répertoire
<b>error_page</b>	Pages d'erreur personnalisées
<b>return</b>	Redirection

## 5. Gestion des Requêtes HTTP

### Étapes du Parsing

1. **Lecture incrémentale** : recv() en boucle jusqu'à avoir la requête complète
2. **Parse Request Line** : Extraire méthode, URI, version
3. **Parse Headers** : Ligne par ligne jusqu'à \r\n\r\n
4. **Parse Body** : Si Content-Length présent (POST)
5. **Validation** : Vérifier conformité HTTP/1.1

### Gestion du Body (POST)

#### Content-Length

Indique la taille exacte du body en octets.

Content-Length: 1234 [1234 octets de données]

- Lire exactement Content-Length octets
- Si reçu plus → erreur 400
- Si reçu moins → attendre plus de données
- Comparer à client\_max\_body\_size → 413 si dépassé

#### Transfer-Encoding: chunked

Le body est envoyé par morceaux (chunks).

Transfer-Encoding: chunked 5\r\nHello\r\n6\r\nWorld!\r\n0\r\n\r\n

Format : taille\_hexa\r\n données\r\n

Fin : 0\r\n\r\n\r\n

### Méthodes HTTP

#### GET

- Récupérer une ressource (fichier, listing)

- Pas de body dans la requête
- Retourner 200 + contenu ou 404

## POST

- Envoyer des données (upload, formulaire)
- Body dans la requête
- Retourner 201 (Created) ou 200

## DELETE

- Supprimer une ressource
- Vérifier les permissions
- Retourner 204 (No Content) ou 200

## 6. CGI (Common Gateway Interface)

### Qu'est-ce que CGI ?

CGI permet au serveur web d'exécuter des scripts externes (Python, PHP, etc.) pour générer du contenu dynamique.

#### Principe :

1. Le serveur détecte une requête pour un script CGI
2. Il lance le script avec `fork()` + `execve()`
3. Passe les infos via variables d'environnement
4. Envoie le body via `stdin` du script
5. Récupère la sortie via `stdout` du script
6. Retourne la sortie au client

### Variables d'Environnement CGI

Variable	Description	Exemple
<b>REQUEST_METHOD</b>	Méthode HTTP	GET, POST
<b>QUERY_STRING</b>	Paramètres URL	name=John&age=30
<b>CONTENT_LENGTH</b>	Taille du body	1234
<b>CONTENT_TYPE</b>	Type du body	application/x-www-form-urlencoded
<b>PATH_INFO</b>	Chemin après script	/extra/path
<b>SCRIPT_NAME</b>	Nom du script	/cgi-bin/script.py
<b>SERVER_PROTOCOL</b>	Version HTTP	HTTP/1.1
<b>HTTP_*</b>	Headers HTTP	HTTP_USER_AGENT

### Implémentation CGI

```
// 1. Créer des pipes int pipe_in[2], pipe_out[2]; pipe(pipe_in); pipe(pipe_out); // 2. Fork pid_t pid = fork(); if (pid == 0) { // Processus enfant // Rediriger stdin/stdout dup2(pipe_in[0], STDIN_FILENO); dup2(pipe_out[1], STDOUT_FILENO); // Fermer les descripteurs inutiles close(pipe_in[0]); close(pipe_in[1]); close(pipe_out[0]); close(pipe_out[1]); // Configurer l'environnement char *env[] = { "REQUEST_METHOD=POST", "CONTENT_LENGTH=100", NULL }; // Exécuter le script char *argv[] = {"./script.py", NULL}; execve(argv[0], argv, env); exit(1); // Si execve échoue } // 3. Processus parent close(pipe_in[0]); close(pipe_out[1]); // Envoyer le body au script (via pipe_in[1]) write(pipe_in[1], body.c_str(), body.size()); close(pipe_in[1]); // Lire la sortie du script (via pipe_out[0]) char buffer[4096]; std::string output; ssize_t n; while ((n = read(pipe_out[0], buffer, sizeof(buffer))) > 0) { output.append(buffer, n); } close(pipe_out[0]); // Attendre la fin du script waitpid(pid, &status, 0);
```

### ⚠️ Timeout CGI

Un script CGI peut prendre trop de temps. Il faut implémenter un timeout :

- Utiliser alarm() ou un timer
- Si timeout, kill(pid, SIGKILL)
- Retourner 500 (Internal Server Error) au client

## Format de Sortie CGI

Le script CGI doit retourner des headers HTTP + body :

```
Content-Type: text/html <html> <body>Hello from CGI!</body> </html>
```

Le serveur doit parser cette sortie et construire une réponse HTTP complète.

## 7. Questions Fréquentes de Défense

### Architecture & Design



#### Expliquez le flux d'une requête dans votre serveur

Configuration → Socket listen → epoll/select → Accept → Read → Parse → Process → Build response → Write → Close/Keep-alive



#### Pourquoi utilisez-vous epoll/select/poll ?

Pour gérer plusieurs connexions simultanées de manière non-bloquante avec un seul thread, ce qui est efficace et scalable.



#### Quelle est la différence entre epoll et select ?

epoll est O(1) et sans limite de FD, select est O(n) et limité à 1024 FD. epoll supporte edge-triggered, select non.



#### Comment gérez-vous les connexions keep-alive ?

On garde la connexion ouverte après la réponse si le header Connection: keep-alive est présent, et on attend une nouvelle requête sur le même socket.

### HTTP & Parsing



#### Comment parsez-vous une requête HTTP ?

1. Request line (méthode, URI, version) → 2. Headers ligne par ligne → 3. Body si Content-Length présent → 4. Validation



#### Comment savez-vous qu'une requête est complète ?

Pour les headers : double CRLF (`\r\n\r\n`). Pour le body : Content-Length octets reçus, ou dernier chunk (`0\r\n\r\n`) en chunked.



#### Comment gérez-vous les requêtes malformées ?

Validation stricte du parsing : méthode invalide, URI malformée, headers incorrects → retourner 400 Bad Request.



#### Quelle est la différence entre 301 et 302 ?

301 = redirection permanente (le client peut mettre en cache). 302 = redirection temporaire (le client ne doit pas mettre en cache).

## CGI



### Expliquez le fonctionnement de CGI

Le serveur fork() un processus enfant, configure l'environnement, redirige stdin/stdout via pipes, exécute le script avec execve(), lit la sortie et retourne au client.



### Comment passez-vous les données au script CGI ?

Variables d'environnement (REQUEST\_METHOD, QUERY\_STRING, etc.) pour les métadonnées. Body via stdin pour les données POST.



### Comment gérez-vous un script CGI qui ne se termine pas ?

Timeout avec alarm() ou timer. Si dépassé, kill(pid, SIGKILL) et retourner 500 au client.



### Pourquoi fork() et pas system() ?

fork() + execve() permet un contrôle total : pipes, environnement, timeout. system() est bloquant et moins sécurisé.

## Configuration & Features



### Comment gérez-vous plusieurs serveurs virtuels ?

Via le header Host dans la requête. On compare Host avec server\_name dans la config pour router vers le bon serveur.



### Comment fonctionne l'autoindex ?

Si aucun fichier index n'existe et autoindex est on, on liste le contenu du répertoire et génère une page HTML avec les liens.



### Comment gérez-vous les uploads (POST) ?

Parser le body (multipart/form-data ou application/octet-stream), extraire le fichier, sauvegarder dans upload\_path avec vérification de taille (client\_max\_body\_size).



### Comment gérez-vous DELETE ?

Vérifier que la méthode est autorisée, vérifier les permissions du fichier, utiliser unlink() pour supprimer, retourner 204 ou 200.

## Sécurité & Gestion d'Erreurs



### Comment empêchez-vous le directory traversal ?

Valider l'URI, résoudre le chemin canonique, vérifier qu'il reste dans le root autorisé.

Bloquer ../ et chemins absous.



#### **Comment gérez-vous les erreurs système (EAGAIN, EPIPE) ?**

EAGAIN/EWOULDBLOCK : normal en non-bloquant, réessayer plus tard. EPIPE : client déconnecté, fermer proprement la connexion.



#### **Que faire si recv() retourne 0 ?**

Le client a fermé la connexion. Nettoyer les ressources et fermer le socket côté serveur.

## 8. Checklist de Vérification

### Fonctionnalités Obligatoires

- ✓ HTTP/1.1 compliant (méthodes GET, POST, DELETE)
- ✓ Configuration via fichier (ports, routes, methods, etc.)
- ✓ Serveurs virtuels (multi-host via server\_name)
- ✓ Pages d'erreur par défaut et personnalisables
- ✓ Limitation de taille du body (client\_max\_body\_size)
- ✓ Routes configurables (location blocks)
- ✓ Support des fichiers statiques
- ✓ Méthodes HTTP autorisées par route
- ✓ Redirections HTTP (301, 302)
- ✓ Directory listing (autoindex on/off)
- ✓ Fichier index par défaut
- ✓ Upload de fichiers (POST)
- ✓ Exécution CGI (scripts externes)
- ✓ Fonctionnement avec navigateur
- ✓ Non-bloquant (epoll/select/poll)
- ✓ I/O multiplexing efficace
- ✓ Gestion propre des erreurs
- ✓ Pas de leaks mémoire
- ✓ Résilience (pas de crash)

### Tests à Effectuer Avant la Défense

#### Tests Basiques :

- Accéder à une page HTML statique
- 404 sur fichier inexistant
- Directory listing avec autoindex
- Redirection fonctionnelle
- Page d'erreur personnalisée

#### Tests POST :

- Upload d'un fichier (formulaire HTML)
- Body trop grand → 413
- Fichier uploadé accessible après

### Tests DELETE :

- Supprimer un fichier existant → 204/200
- Supprimer un fichier inexistant → 404
- DELETE non autorisé → 405

### Tests CGI :

- Script Python/PHP simple
- GET avec query string
- POST avec body au script
- Timeout CGI géré

### Tests Stress :

- Siege : siege -c 100 -t 30s http://localhost:8080/
- Multiple connexions simultanées
- Pas de crash, pas de leak

# Conseils pour la Soutenance

## Préparation

- **Connaître votre code** : Soyez capable d'expliquer chaque partie
- **Tester avant** : Vérifiez que tout fonctionne, y compris les edge cases
- **Préparer des exemples** : Ayez des fichiers de test (HTML, scripts CGI, config)
- **Vérifier les leaks** : Valgrind doit être clean
- **Maîtriser votre config** : Savoir expliquer chaque directive

## Pendant la Défense

- **Restez calme** : Si vous ne savez pas, admettez-le honnêtement
- **Expliquez votre raisonnement** : Pourquoi ces choix de design ?
- **Montrez votre compréhension** : Concepts HTTP, I/O multiplexing, CGI
- **Soyez précis** : Évitez les généralités, donnez des détails techniques
- **Défendez vos choix** : epoll vs select ? Pourquoi ?

## Points Clés à Maîtriser

1. **Le protocole HTTP** : Structure, codes, méthodes
2. **L'I/O multiplexing** : Pourquoi, comment, différences
3. **Le parsing** : Comment détecter une requête complète
4. **CGI** : Fork, pipes, environnement, timeout
5. **La configuration** : Directives, virtual hosts, locations

## ⚠ Pièges à Éviter

- Ne pas savoir expliquer pourquoi vous avez choisi epoll/select/poll
- Confondre les codes HTTP (301 vs 302, 400 vs 500)
- Ne pas gérer correctement le mode non-bloquant (EAGAIN)
- Oublier le timeout CGI
- Leaks mémoire sur les cas d'erreur
- Directory traversal non sécurisé

# Ressources Utiles

## Documentation Officielle

- **RFC 2616** : HTTP/1.1 (remplacée par RFC 7230-7235)
- **RFC 3875** : CGI specification
- **man pages** : socket, bind, listen, accept, epoll, select, fork, execve

## Outils de Test

- **curl** : Tester les requêtes HTTP depuis la ligne de commande
- **Postman** : Interface graphique pour tester les API
- **siege** : Load testing et benchmark
- **netcat (nc)** : Envoyer des requêtes brutes
- **telnet** : Connexion manuelle au serveur
- **valgrind** : Détection de leaks mémoire

## Commandes Utiles

```
# Tester avec curl curl -X GET http://localhost:8080/ curl -X POST -d "data"  
http://localhost:8080/upload curl -X DELETE http://localhost:8080/file.txt # Envoyer une requête  
brute echo -e "GET / HTTP/1.1\r\nHost: localhost\r\n\r\n" | nc localhost 8080 # Load testing  
siege -c 100 -t 30s http://localhost:8080/ # Vérifier les leaks valgrind --leak-check=full ./webserv  
config.conf # Monitorer les connexions netstat -an | grep 8080 lsof -i :8080
```

Bonne Chance pour la Défense !

Vous avez tout ce qu'il faut pour réussir !

